EUCYS 2026

PI–CVAE

Physics-Informed Conditional Variational Autoencoder

do generacji pól plazmowych SOLPS-ITER

CNN + Transformer

Przestrzeń latentna 128

Straty fizyczne

ARCHITEKTURA MODELU — PRZEGLĄD

Motywacja: po co emulator plazmy?

PI-CVAE to sieć neuronowa zastępująca kosztowne obliczenia numeryczne błyskawicznym przewidywaniem.

Problem

Symulator SOLPS-ITER oblicza fizykę plazmy równaniami różniczkowymi — jedno uruchomienie trwa ***wiele godzin***

→

Rozwiązanie

Sieć neuronowa uczy się wzorców z tysięcy gotowych symulacji i odpowiada w ***ułamku sekundy***

→

Zastosowanie

Szybka optymalizacja parametrów reaktora i analiza wrażliwości bez uruchamiania SOLPS

Kontekst fizyczny

Tokamak to reaktor fuzji jądrowej — w nim wodór podgrzewany jest do temperatury wyższej niż wnętrze Słońca i utrzymywany silnym polem magnetycznym. Strefa **SOL (Scrape-Off Layer)** to cienka warstwa plazmy tuż przed ścianką reaktora, kluczowa dla jego bezpieczeństwa i wydajności.

SOLPS-ITER to profesjonalny program numeryczny symulujący fizykę tej strefy — jednak jego uruchomienie trwa godziny, a optymalizacja wymaga tysięcy takich obliczeń.

Co to jest sieć neuronowa?

Sieć neuronowa to program komputerowy uczący się wzorców z danych — podobnie jak dziecko uczy się rozpoznawać koty z tysięcy zdjęć, sieć uczy się przewidywać wyniki SOLPS na podstawie gotowych symulacji.

PI-CVAE przyjmuje **8 liczb** opisujących warunki eksperymentu (np. moc grzewcza w MW, natężenie pola magnetycznego w T) i generuje **22 mapy** rozkładu temperatury, gęstości i prędkości plazmy na przekroju SOL.

> **Innymi słowy:** Zamiast liczyć fizykę od nowa, model „przypomina sobie" podobne przypadki ze zbioru treningowego i interpoluje odpowiedź.

PI-CVAE: architektura modelu

Model zbudowany jest z trzech współpracujących modułów: enkodera, prioru i dekodera.

Dane wejściowe i wyjściowe

Model przyjmuje **22 mapy fizyczne plazmy** na siatce 104×50 punktów oraz **8 liczb** opisujących globalny stan reaktora — i generuje 22 mapy z powrotem.

22 mapy to: temperatura elektronów i jonów (T_e, T_i), gęstości 10 gatunków jonów (n_a) i ich prędkości (u_a). Każda mapa to obraz 104×50 — jak czarno-biała fotografia przekroju SOL.

Innymi słowy: Tensor 22×104×50 to po prostu 22 takich fotografii ułożonych w stos — jak strony atlasu anatomicznego, gdzie każda strona pokazuje inną wielkość fizyczną.

$22 \times 104 \times 50$

22 kanały

104 × 50

Główna idea — trzy moduły

Physics-Informed Conditional VAE łączy trzy moduły:

- **Enkoder** — analizuje wejściowe mapy i streszcza je do krótkiego wektora liczb,
- **Prior** — przewiduje, jak ten skrót powinien wyglądać na podstawie samych warunków globalnych,
- **Dekoder** — na podstawie skrótu i warunków odtwarza pełne mapy.

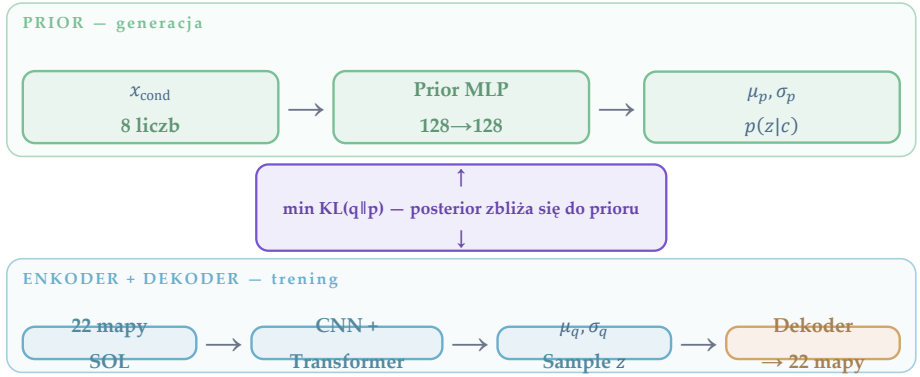

Kolejność operacji

IN

1. Wejście

22 mapy + 8 liczb stanu

2. Enkoder

streszcza dane do z

3. Prior

przewiduje zakres z

z

4. Dekoder

z z i warunków odtwarza mapy

OUT

5. Wyjście

22 mapy 104 × 50

Schemat ogólny

Model przetwarza dane w trzech etapach: wczytanie → kompresja do reprezentacji wewnętrznej → odtworzenie.

IN

1. Dane wejściowe

22 mapy plazmy + 8 liczb (warunki reaktora)

→

z

2. Kompresja

model zapisuje esencję stanu w 128 liczbach

→

OUT

3. Rekonstrukcja

z 128 liczb odtwarzane są pełne mapy

Co wchodzi do modelu?

- T_e, T_i — temperatura elektronów i jonów (w elektronowoltach),
- n_a **× 10** — gęstości różnych gatunków jonów (w m$\{\}^{-3}$),
- u_a **× 10** — prędkości jonów wzdłuż linii pola (w m/s),
- x_{cond} **× 8** — warunki globalne: moc grzewcza, pole magnetyczne, gęstość wejściowa i inne.

Innymi słowy: Każda z 22 map to „termiczny obraz" innej wielkości fizycznej — razem tworzą kompletny opis stanu SOL.

Co znaczy "reprezentacja latentna"?

Model nie zapamiętuje 22 pełnych map — sprowadza je do **128 liczb** ($z \in \mathbb{R}^{128}$) opisujących esencję stanu plazmy.

Innymi słowy: Analogia: zamiast pamiętać pełny atlas anatomiczny pacjenta, lekarz zapisuje w karcie kilka kluczowych parametrów (temperatura, ciśnienie, wyniki badań). Dekoder to lekarz, który z tych skrótów odtwarza pełny obraz stanu zdrowia.

*Model jest **rekonstruktorem**: wyjście ma taki sam kształt jak wejście — nie klasyfikuje danych, lecz odtwarza je z kompresji.*

Rola poszczególnych bloków

Enkoder przetwarza dane, prior wyraża oczekiwania, a dekoder odtwarza obrazy fizyczne.

Enkoder

analizuje mapy i wyciąga to, co istotne

→

z

Wektor latentny

128 liczb = „streszczenie" stanu

→

Prior

sprawdza, czy streszczenie pasuje do warunków

→

OUT

Dekoder

ze streszczenia odtwarza pełne mapy 2D

Co robi każdy moduł?

- **Enkoder** przegląda 22 mapy i wydobywa z nich cechy charakterystyczne — jak ekspert analizujący wyniki badań.
- **Wektor latentny** z to wynik tej analizy: 128 liczb opisujących stan plazmy — jak streszczenie artykułu zamiast całego tekstu.
- **Prior** wyraża oczekiwania: wiedząc, jakie są warunki globalne (8 liczb), model przewiduje, jak z powinno wyglądać.
- **Dekoder** działa odwrotnie: z z i warunków rekonstruuje 22 pełne mapy.

Pytania, na które odpowiada architektura

- **Enkoder**: Które cechy map plazmy są najważniejsze dla opisu stanu SOL?
- z: Jak zakodować kompletną wiedzę o stanie plazmy w 128 liczbach?
- **Prior**: Jakich wartości z spodziewamy się przy danych warunkach reaktora?
- **Dekoder**: Jak z tego kodu odtworzyć pełny, fizycznie poprawny obraz SOL?

Razem tworzą zamkniętą pętlę: ściskaj ⟶ sprawdź spójność ⟶ rozpakowuj.

Przepływ danych przez model

W fazie treningu enkoder jest aktywny; w fazie generacji pomijamy go i próbkujemy z prioru.

IN

Wejście pól

22 mapy, tensor 22 × 104 × 50

→

Enkoder

CNN + Transformer wyciąga cechy

→

Posterior

$q(\mu, \sigma^2)$ — *opis rozkładu* z *z DANYCH*

Warunki

x_{cond} — *8 liczb opisujących stan reaktora*

→

PriorNet

$p(\mu, \sigma^2 \mid c)$ — *opis rozkładu* z *z WARUNKÓW*

→

z

Próbkowanie z

losowanie z rozkładu (reparametryzacja)

Trening vs generacja

Podczas treningu

Enkoder patrzy na prawdziwe mapy i wyznacza rozkład q opisujący, „czym jest z“. Model uczy się, by q był bliski priorowi p.

Podczas generacji

Enkoder jest wyłączony. Model losuje z z prioru $p(z|c)$ — tj. na podstawie samych warunków — i dekoduje nowe mapy.

Innymi słowy: To jak

z

z + warunki c

konkatenacja wektora z z 8 liczbami

→

Dekoder

dekonwolucje + bloki residualne

→

OUT

Wyjście

22 zrekonstruowane mapy SOL

Fizyka wbudowana w model

Trzy człony kary w funkcji straty nie pozwalają sieci generować fizycznie niemożliwych wyników.

Nieujemność

Temperatura i gęstość plazmy nigdy nie mogą być ujemne — to fundamentalne prawo fizyki.

$$T_e, T_i \geq 0, \quad n_a \geq 0$$

Innymi słowy: Bez tej kary sieć mogłaby generować „ujemną gęstość" — liczby matematycznie sensowne, ale fizycznie bezsensowne. Kara wymusza poprawność.

Kryterium Bohma

Jony w SOL nie mogą poruszać się szybciej niż prędkość dźwięku w plazmie (c_s) — tak jak przepływ gazów w zwężeniu.

$$|u_a| \leq c_s = \sqrt{(T_e + T_i)/m}$$

Innymi słowy: To odpowiednik ograniczenia prędkości: jony przyspieszają, ale na granicy reaktora nie przekraczają „bariery dźwięku plazmy".

Zachowanie strumienia

Strumień cząstek $\Gamma = n \cdot u$ powinien być bezrozbieżny — cząstki nie mogą „znikać" ani „pojawiać się" bez źródła.

$$\nabla \cdot (n_a u_a) \approx 0$$

Innymi słowy: Analogia: jeśli tyle samo wody wpływa rurą co wypływa, dywergencja strumienia jest zerowa. Model uczy się tej zasady zachowania.

Całkowita funkcja straty — co model minimalizuje podczas treningu?

$$L = \underbrace{L_{\text{rec}}}_{\text{rekonstrukcja}} + \beta_{\text{KL}} \cdot \underbrace{\text{KL}(q \,\|\, p)}_{\text{spójność}} + w_1 \underbrace{L_{\text{nonneg}}}_{\text{fizyka 1}} + w_2 \underbrace{L_{\text{Bohm}}}_{\text{fizyka 2}} + w_3 \underbrace{L_{\text{div}}}_{\text{fizyka 3}}$$

L_{rec} — jak bardzo mapy różnią się od oryginału; KL — czy rozkład z pasuje do prioru; w_1, w_2, w_3 — wagi kar fizycznych.

◆ *β_{KL} rośnie od 0 do 1 przez pierwsze 50 epok (KL annealing) — model uczy się najpierw rekonstruować, a dopiero potem spełniać ograniczenia statystyczne.*

Enkoder hybrydowy: CNN + Transformer

Dwa uzupełniające się mechanizmy: CNN widzi lokalne wzorce, Transformer — globalne zależności.

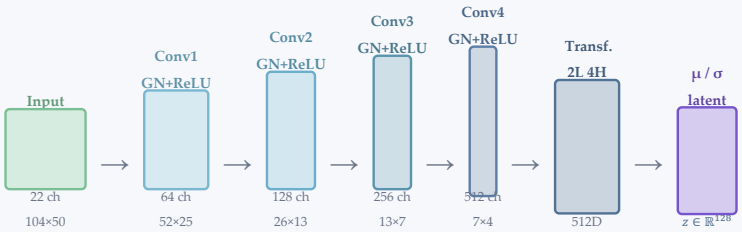

Część CNN — lokalne cechy przestrzenne

Splotowa sieć neuronowa (CNN) przesuwa małe „okno" po mapie i wykrywa lokalne wzorce (gradienty temperatury, fronty gęstości). Każda warstwa patrzy na coraz szerszy obszar:

Conv2d: 22 → 64 → 128 → 256 → 512 kanałów (stride 2 = zmniejsza rozmiar ×2 co warstwę)

Po każdej warstwie:

GroupNorm — stabilizacja uczenia

ReLU — nieliniowość

Innymi słowy: CNN działa jak lekarz przeglądający zdjęcie RTG — najpierw widzi ostre krawędzie, potem rozpoznaje większe struktury.

◆ *CNN widzi drzewo, Transformer widzi las. Łącząc oba, enkoder rozumie zarówno lokalne struktury SOL jak i spójność globalną całego profilu.*

Część Transformer — globalne zależności

Mapy ze 512 kanałami są rozkładane w sekwencję tokenów (jak piksele w obrazie zamieniają się w „słowa“):

$$512 \times H \times W \rightarrow (H \cdot W) \times 512$$

2 warstwy Transformer z mechanizmem **self-attention**: każdy token pyta pozostałe o ich wartość. Wynik: 512-wymiarowy wektor globalny.

> **Innymi słowy:** Transformer widzi cały przekrój SOL jednocześnie — temperatura przy ściance może wpływać na interpretację gęstości w centrum.

Wyjście enkodera — parametry rozkładu

512-wymiarowy wektor przechodzi przez dwie warstwy liniowe, wyznaczając parametry rozkładu normalnego:

$$\mu_q \quad \text{i} \quad \log \sigma_q^2 : 512 \rightarrow 128$$

> **Innymi słowy:** Enkoder nie zwraca jednej odpowiedzi, lecz **rozkład**: środek μ i szerokość σ — jak powiedzenie „z ma wartość $\mu \pm \sigma$“. To pozwala modelowi wyrazić niepewność.

Domyślnie $d_{\text{latent}} = 128$.

Przestrzeń latentna i prior warunkowy

Przestrzeń latentna to skompresowany opis stanu plazmy; prior wyraża, jakich opisów się spodziewamy.

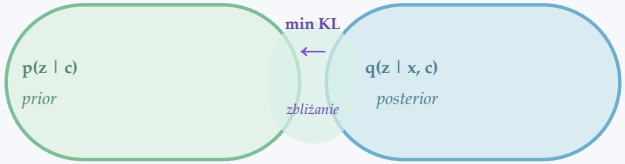

Trening: min KL(q ‖ p) — posterior zbliża się do prioru

Posterior q(z | x, c) — opis z danych

Enkoder wyznacza rozkład z na podstawie **rzeczywistych map**:

$$q_{\{\mu\}}, q_{\{\log \sigma^2\}} = \text{Enkoder}(x_{\text{field}}, c)$$

Próbka pobierana jest metodą reparametryzacji (różniczkowalny trik):

$$z = \mu + \varepsilon \cdot \sigma, \quad \varepsilon \sim \mathcal{N}(0, I)$$

Innymi słowy: „Posterior" — co wynika z danych. Enkoder patrzy na prawdziwe mapy i mówi: „z prawdopodobnie jest w tym rejonie przestrzeni latentnej."

Conditional Prior Network p(z | c) — oczekiwania z warunków

Prior to osobna sieć MLP (prosta sieć w pełni połączona), która widzi *tylko* 8 liczb warunków globalnych:

- Linear: 8 → 128 → 128
- Dwie głowice: μ_p i $\log \sigma_p^2$

Uczy się: „jeśli moc grzewcza wynosi X i pole magnetyczne Y, to z powinno leżeć w tej okolicy przestrzeni latentnej."

Innymi słowy: „Prior" — oczekiwania PRZED zobaczeniem danych. Jak lekarz mówi: „przy tej diagnozie spodziewamy się takich wyników" — zanim zobaczy konkretny przypadek.

Po co przestrzeń latentna?

- **Kompresja**: 22 map 2D ⟶ 128 liczb.
- **Niepewność**: zamiast jednego punktu, model podaje rozkład możliwych stanów.
- **Różnorodność**: z tych samych warunków można próbkować wiele fizycznie poprawnych realizacji.

Innymi słowy: To jak encyklopedia skrótów: zamiast całego tomu, 128 liczb opisuje stan plazmy tak jak sygnatura chemiczna opisuje związek.

◆ *Standardowy VAE losuje z z $\mathcal{N}(0, I)$ — szum bez sensu fizycznego. Tu prior jest uczony: losujemy z rozkładu dostosowanego do konkretnych parametrów reaktora, więc każda próbka jest fizycznie sensowna.*

Jak łączymy prior i posterior?

Model minimalizuje $\mathrm{KL}(q \,\|\, p)$ — miarę odległości między rozkładem wyznaczonym z danych a oczekiwanym przez prior. Jeśli są zgodne, z z prioru daje realistyczne mapy w fazie generacji.

Dekoder residualny i rekonstrukcja pól

Dekoder przetwarza skompresowany opis z powrotem na 22 pełne mapy fizyczne przy użyciu bloków residualnych.

Wejście i rozwinięcie do siatki

Dekoder łączy wektor latentny z z warunkami c w jeden wektor wejściowy:

$$\text{concat}(z, c) \in \mathbb{R}^{128+8} = \mathbb{R}^{136}$$

Dwie warstwy liniowe „rozwijają“ go do przestrzennej siatki:

- Linear: 136 → 512
- Linear: 512 → $512 \times 13 \times 7$ (mała siatka 13×7)

Innymi słowy: To jak narysowanie bardzo małego szkicu (13×7 punktów) z krótkiego opisu tekstowego — szczegóły zostaną dodane w następnych krokach.

Czym są bloki residualne (ResBlock)?

ResBlock oblicza $y = f(x) + x$ — do wyniku dodaje **oryginalne wejście**:

$$y = \text{Conv}(\text{Conv}(x)) + x$$

Innymi słowy: To jak „ścieżka obejścia“: gradient może płynąć bezpośrednio przez dodanie x, omijając głębokie warstwy. Bez tego, sygnał znika lub eksploduje w wielowarstwowym dekoderze.

Bez ResBlock: głęboki dekoder 22 kanałów po wielu dekonwolucjach jest niestabilny numerycznie i trudny w treningu.

Stopniowe powiększanie przez dekonwolucje

Trzy etapy powiększania (upsampling) z blokami residualnymi:

- ConvTranspose2d: 512→256 + ResBlock(256)
- ConvTranspose2d: 256→128 + ResBlock(128)
- ConvTranspose2d: 128→64 + ResBlock(64)
- Ostatnia warstwa: Conv2d: 64 → 22

Na końcu interpolacja biliniowa do dokładnego rozmiaru **104×50**.

Po co dekoder widzi i z i warunki c?

z koduje "co" (stan wewnętrzny plazmy), a c koduje "w jakich warunkach" (parametry reaktora). Razem pozwalają dekoderowi generować różne mapy dla różnych eksperymentów przy tym samym z — model jest **elastyczny** i **warunkowy**.

Najważniejsze cechy architektury

Lokalne i globalne zależności

CNN wykrywa lokalne wzorce przestrzenne, Transformer modeluje zależności dalekiego zasięgu. Ich połączenie wystarcza do opisu SOL.

Warunkowanie — generacja na żądanie

Podając 8 liczb x_{cond}, model generuje realistyczne mapy SOL bez SOLPS-ITER. Prior warunkowy gwarantuje fizyczną spójność.

Stabilna rekonstrukcja 22 kanałów

Bloki residualne umożliwiają trenowanie głębokiego dekodera bez zaniku gradientu — model odtwarza wszystkie 22 pola plazmy.

Physics-Informed — fizyka jako ograniczenie

Trzy człony kary w L (nieujemność, kryterium Bohma, dywergencja strumienia) sprawiają, że sieć nigdy nie generuje fizycznie niemożliwych pól. To kluczowa różnica od zwykłego ML — model „rozumie" prawa fizyki plazmy.

Podsumowanie w jednym zdaniu

PI-CVAE to warunkowy autoenkoder wariacyjny: enkoder (CNN + Transformer) streszcza 22 mapy do 128 liczb, prior przewiduje stan z 8 parametrów reaktora, a dekoder residualny odtwarza SOL w milisekundy — milion zapytań w ciągu minut.