PI–CVAE: Physics-Informed Conditional Variational Autoencoder

Głęboki emulator pól plazmowych strefy SOL dla tokamaka — generacja w milisekundy zamiast godzin symulacji SOLPS-ITER

Głębokie uczenie · Emulator fizyczny · Physics-Informed AI

1. Problem i motywacja

Fuzja termojądrowa jest potencjalnie **nieograniczonym, bezemisyjnym źródłem energii**. **Tokamak** (np. ITER) utrzymuje plazmę w temperaturze przekraczającej **100 mln °C** silnym polem magnetycznym.

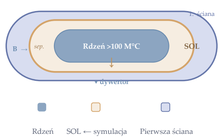

Strefa **SOL (Scrape-Off Layer)** — obszar między rdzeniem plazmy a pierwszą ścianą — decyduje o trwałości reaktora. Kod **SOLPS-ITER** symuluje SOL z dużą dokładnością, lecz **jedno uruchomienie trwa wiele godzin**. Optymalizacja wymagałaby **dziesiątek tysięcy** takich biegów.

◆ *Cel: sieć neuronowa zastępująca SOLPS-ITER, generująca kompletny stan SOL w 1 ms, przy zachowaniu praw fizyki.*

2. Dane wejściowe i wyjściowe

$x_{\text{cond}} \in \mathbb{R}^8$ — Moc grzewcza, pole B, gęstość linii pola, … → **PI-CVAE** (Prior MLP · Enkoder · CNN+Transf. · Dekoder Res) → $x_{\text{rec}} \in \mathbb{R}^{22\times104\times50}$ — $T_e, T_i, n_a (\times 10), u_a (\times 10)$

Model przyjmuje **8 parametrów eksperymentu** i generuje **22 mapy 2D (104×50 siatek)**:

- T_e, T_i — temperatura e^- i jonów
- $n_a \times 10$ — gęstości 10 gatunków
- $u_a \times 10$ — prędkości jonów wzdłuż $\boldsymbol{B}$
- łącznie: 22 × 104 × 50 = **114 400 wartości**

Każda mapa to fizyczny „przekrój" innej wielkości przez strefę SOL — razem tworzą pełny opis stanu plazmy.

3. Normalizacja danych

Wartości (T_e, n_a) obejmują wiele rzędów wielkości (np. 10^{18}–10^{22} m⁻³). Stosujemy **log-normalizację**:

$$\hat{T}_e = \frac{\ln(1+T_e) - \mu_{\log}}{\sigma_{\log}}$$

Prędkości u_a (znak ± zachowany) standaryzujemy zwykłą z-normalizacją: $\frac{u-\mu}{\sigma}$. Warunki x_{cond} również standaryzujemy osobno.

Dane surowe → $\ln(1+x)$ + z-norm. → Dane norm.

Log-transform spłaszcza rozpiętość wartości; normalizacja centruje rozkład — sieć uczy się stabilniej i szybciej.

4. Architektura PI-CVAE

Model składa się z trzech modułów działających wspólnie:

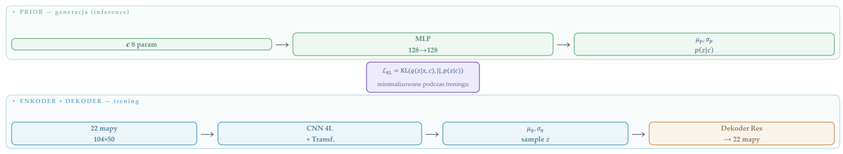

Enkoder hybrydowy (CNN + Transformer)

22 mapy 104×50 → CNN 4L → Transformer 2L → μ_q, σ_q ∈ R¹²⁸

Prior warunkowy (MLP)

8 param. → MLP [128→128→128] → μ_p, σ_p — uczony, nie N(0,1)

Dekoder residualny (ConvTranspose + ResBlock)

concat(z, c) ∈ R¹³⁶ → FC → 13×7 → 3× upsampling → 22 mapy 104×50

◆ *Inference: pomijamy enkoder; próbkujemy $z \sim p(z|c)$ z prioru i dekodujemy — brak potrzeby danych x.*

5. Enkoder hybrydowy CNN + Transformer

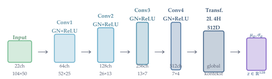

CNN (4 warstwy) — splot 3×3, GroupNorm, ReLU, stride 2. Każda **Transformer (2L, 4H)** — cechy 512D tokenizowane i przekształcane warstwa redukuje przestrzeń 2× i podwaja kanały. Wydobywa self-attention. Modeluje **globalne zależności** struktury SOL. **lokalne wzorce** pola.

CNN + Transformer: lokalna precyzja + globalny kontekst → kompletne, spójne streszczenie pola w 128-wymiarowej przestrzeni latentnej.

6. Przestrzeń latentna i prior warunkowy

Enkoder nie zwraca punktu, lecz **rozkład Gaussa**:

$$z = \mu_q + \varepsilon \cdot \sigma_q, \quad \varepsilon \sim \mathcal{N}(0, \boldsymbol{I}), \quad z \in \mathbb{R}^{128}$$

Minimalizacja KL zbliża posterior (Enkoder) do prioru (MLP) — po treningu generujemy z p(z|c)

Prior warunkowy: MLP przewiduje $p(z|c) = \mathcal{N}\left(\mu_{p(c)}, \sigma_p^2(c)\right)$ z 8 parametrów. Trening minimalizuje $\mathrm{KL}(q \parallel p)$, zbliżając posterior do prioru.

Kluczowa różnica względem standardowego VAE: prior jest **uczony** — model wie, jaki rozkład latentny jest właściwy dla danych parametrów reaktora.

7. Wbudowane ograniczenia fizyczne

PI-CVAE kara sieć za naruszenie praw fizyki podczas treningu:

- Nieujemność $T_e, T_i, n_a \geq 0$
- Kryterium Bohma $|u_a| \leq c_s$
- Zachowanie strumienia

I. **Nieujemność** ($T_e, T_i, n_a ge 0$): temperatura i gęstość nie mogą być ujemne. Kara: $L_{\text{nn}} = \text{mean}(\text{ReLU}(-\hat{x})^2)$.
II. **Kryterium Bohma** $|u_a|\ lec_s = \sqrt{\frac{T_e+T_i}{m_a}}$: prędkość jonów ograniczona prędkością dźwięku w plazmie.
III. **Zachowanie strumienia** $\nabla \cdot (n_a u_a) \approx 0$: brak źródeł/ujść cząstek wewnątrz domeny. Dywergencja aproksymowana różnicami centralnymi.

8. Funkcja straty i procedura treningu

$$\mathcal{L} = \underbrace{L_{\text{rec}}}_{\text{MSE}} + \beta \underbrace{L_{\text{KL}}}_{\text{spójność}} + w_1 \underbrace{L_{\text{nn}}}_{\geq 0} + w_2 \underbrace{L_{\text{Bohm}}}_{\text{Bohm}} + w_3 \underbrace{L_{\text{div}}}_{\nabla \cdot j}$$

- Optymalizator: Adam, lr $= 2 \times 10^{-4}$
- Batch: 128, do 500 epok
- Gradient clipping: 5.0
- ReduceLROnPlateau + early stopping
- Mixed precision (AMP) na GPU
- KL annealing: $\beta : 0 \to 1$ przez 100 epok
- $w_1 = 10^{-3}$ (nieujemność)
- $w_2 = 5 \times 10^{-4}$ (Bohm)
- $w_3 = 3 \times 10^{-3}$ (zachowanie strumienia)
- GroupNorm zamiast BatchNorm (stabilność)

KL annealing zapobiega kolapsowi posterioru — posterior stopniowo się uczy zamiast od razu kolapować do prioru.

9. Dekoder residualny

Dekoder odwzorowuje $\text{concat}(z, c) \in \mathbb{R}^{136}$ na 22 mapy 104×50:

$$\mathbb{R}^{136} \to \text{FC}(2048) \to \text{reshape } 13 \times 7 \to 3 \times [\text{ConvTranspose} + \text{ResBlock}] \to \text{Conv 22ch} \to 104 \times 50$$

Każdy blok ConvTranspose (512→256→128→64) uzupełniony **blokiem residualnym**:

skip connection: x dodawane bezpośrednio do wyjścia (tożsamość)

x → Conv2d 3×3 GN + ReLU → Conv2d 3×3 GroupNorm → (+) → y

Skip connections utrzymują gradient płynący podczas treningu — dekoder stabilnie rekonstruuje wszystkie 22 pola fizyczne bez zanikania gradientu.

Hybrydowy enkoder

CNN wychwytuje lokalne wzorce plazmy; Transformer modeluje globalne zależności zasięgu — razem kodują pełny stan SOL w 128 liczbach.

Warunkowa generacja

Wystarczy 8 parametrów eksperymentu, by model natychmiast wygenerował 22 realistyczne mapy SOL — bez żadnej symulacji SOLPS-ITER.

Prawa fizyki jako ograniczenia

Trzy kary (nieujemność, kryterium Bohma, zachowanie strumienia) gwarantują, że sieć *nigdy* nie wygeneruje niefizycznych wyników.

Kluczowy wynik

PI-CVAE generuje kompletny opis stanu SOL w **1 ms** zamiast godzin — umożliwiając kampanie optymalizacyjne dotychczas **praktycznie niemożliwe do przeprowadzenia**.